

Автоматический видеомонтаж

Сводные рекомендации по алгоритмам и методам

Цель документа — дать готовый перечень проверенных методов и алгоритмов для автоматизации монтажа коротких роликов (Reels / Shorts / TikTok): как определять качественные кадры, оценивать их по смыслу, кадрировать под вертикаль и синхронизировать склейки с музыкой.

Область применения. Документ сознательно НЕ описывает архитектуру пайплайна (её собираем отдельно). Здесь — только рекомендации по конкретным алгоритмам, моделям, библиотекам, пороговым значениям и метрикам. Каждый раздел = одна задача монтажа; внутри — рекомендуемый метод, обоснование, инструмент и параметры.

Скомпоновано из 4 технических аналитических записок. стек ориентирован на Python + open source.

0. Карта задач монтажа и рекомендуемых методов

Сводка «задача → метод первого выбора». Детали и параметры — в соответствующих разделах.

Задача монтажа	Метод / модель первого выбора	Библиотека
Хороший/брак кадр (резкость)	Дисперсия Лапласиана, порог	OpenCV
Экспозиция, свет	Гистограмма яркости Y (YUV/HSV)	OpenCV
Эстетика кадра	NIMA (CNN, датасет AVA) → 1–10	PyTorch / TF
Смысл кадра / поиск по тексту	CLIP-эмбединги + cosine similarity	CLIP, Transformers
Куда смотрит зритель	Saliency: U2-Net / DeepGaze / SAM	PyTorch
Границы сцен (шотов)	Сравнение гистограмм HSV; TransNet v2	PySceneDetect
Лучшие фрагменты (хайлайты)	Взвешенный скоринг + аудио-триггеры	своя ф-я + librosa
Движение / стабильность	Оптический поток (Farneback / DIS / RAFT)	OpenCV
Кадрирование 9:16	MediaPipe/YOLO + сглаживание траектории	MediaPipe, scipy
Синхронизация под музыку	beat_track (onset + DP)	librosa
Речь и тишина	Silero VAD + Whisper (word timestamps)	Silero, faster-whisper

1. Технический отбор кадров: «хороший» против «брака»

Первый фильтр. Дёшево по вычислениям, отсекает большую часть мусора до тяжёлых нейросетей. Работает покадрово (для анализа достаточно 1–2 кадра/сек).

1.1. Резкость / смаз (Blur Detection)

Метод: Дисперсия Лапласиана — $\text{Var}(\text{Laplacian}(I))$. Свёртка кадра ядром Лапласа, затем дисперсия результата.

Логика: Резкий кадр богат высокочастотными деталями → высокая дисперсия. Смазанный → низкая.

Порог: Если $\text{Var} < \sim 100$ — кадр считается смазанным и выбраковывается (порог калибруется под камеру/контент).

Альтернатива: Измерение ширины краёв (edge width), частотный анализ (доля ВЧ-энергии), BRISQUE (no-reference IQA).

Инструмент: OpenCV — `cv2.Laplacian(gray, cv2.CV_64F).var()`.

1.2. Экспозиция и освещённость

Метод: Анализ гистограммы яркости. Канал Y в YUV либо V/яркость в HSV.

Логика: Штраф кадрам с «пережжёнными» (clipping в белый) и «проваленными» в чёрный пикселями; оценка средней яркости.

Параметр: Exposure Score = доля пикселей в зонах пере/недосвета; отсекать кадры с преобладанием чистого чёрного/белого.

Инструмент: OpenCV (`cv2.calcHist`), numpy.

1.3. Шум, цвет, стабильность

- Цветовой баланс: соотношение средних по RGB, оценка цветовой температуры.
- Уровень шума (NoiseLevel) — входит в технический скор со знаком минус.
- Стабильность/тряска: дисперсия оптического потока между кадрами (см. раздел 8).
- No-reference IQA без эталона: BRISQUE (есть в OpenCV-contrib), CLIP-IQA, DIQA (TensorFlow).

Рекомендация. Соберите технический скор кадра как взвешенную сумму: $Q_{tech} = w_1 \cdot \text{Резкость} + w_2 \cdot \text{Экспозиция} + w_3 \cdot (1 - \text{Шум})$. Это бинарный/непрерывный фильтр ПЕРЕД дорогими моделями (NIMA, CLIP, YOLO) — экономит вычисления на порядки.

2. Эстетическая оценка кадра (Aesthetic Scoring)

Когда технический брак отсеян, нужно ранжировать дубли и выбирать «красивые» кадры. Субъективную «красоту» оцифровывают обученными на оценках людей нейросетями.

2.1. Нейросетевые оценщики

Модель	Что делает	Особенности
NIMA (Neural Image Assessment)	CNN, обучена на датасете AVA. Выдаёт оценку 1–10	Промышленный стандарт; влияет на ранжирование дублей
LAION Aesthetic Predictor	Лёгкий регрессор поверх CLIP-эмбеддингов	Быстрый, хорошо коррелирует с «вкусом» соцсетей
CLIP-IQA	Оценка качества/эстетики через CLIP	No-reference, без отдельного обучения
DIQA (Deep Image QA)	Objective error map + subjective score	TensorFlow 2.0 / Keras; есть готовые веса

2.2. Композиционные эвристики (без нейросети)

- Правило третей: вычисление центроидов объектов и проверка их близости к узлам сетки третей.
- Симметрия: детекция симметрии по признакам изображения.
- Главный объект в кадре: размер и положение salient-объекта/лица (см. раздел 3).
- Глубина кадра: depth estimation (стерео/одиночное) — как доп. признак «кинематографичности».

Рекомендация. NIMA/LAION запускайте ТОЛЬКО на кадрах-кандидатах, прошедших технический фильтр раздела 1 — пок кадровый прогон нейросети по всему видео избыточно дорог.

3. Смысловая оценка кадра и карты внимания

3.1. Семантическая привлекательность (CLIP)

Метод: Кадр кодируется в вектор моделью CLIP (OpenAI). Текстовый промпт-сценарий кодируется тем же CLIP.

Метрика: Косинусное сходство (cosine similarity) между эмбеддингом кадра и промптом = «семантическая релевантность».

Пример промпта: "cinematic lighting, perfectly framed, high quality" или "человек у микрофона".

Применение: Поиск кадров по текстовому запросу, отбор фрагментов под заданную тему, доп. эстетический сигнал.

Альтернатива: BLIP / BLIP-2 — генерация текстового описания кадра (captioning) для последующего NLP-отбора.

Инструмент: CLIP (HuggingFace Transformers), PyTorch.

3.2. Наличие главного объекта

- YOLOv8 (ultralytics): детекция людей/объектов — есть ли в кадре значимый субъект.
- Используется и как семантический сигнал (объект есть → кадр ценнее), и как вход для авто-кропа (раздел 9).

3.3. Saliency Detection (карты внимания)

Зачем: Определить пиксели, притягивающие взгляд, чтобы при кропе фокус внимания не уезжал за край кадра.

Подход	Модель / алгоритм	Характер
Классический (контраст)	Itti–Koch	Быстрый, без обучения
Deep learning	U2-Net, SALGAN, DeepGaze	Точные карты внимания
Сегментация объектов	SAM (Segment Anything)	Выделение foreground-объекта целиком

Применение: Центр масс salient-карты задаёт центр окна кропа 9:16, когда лиц в кадре нет.

Гибридная рекомендация для авто-кропа: комбинируйте трекинг лица с картой салиентности. Чистый трекинг лица «мёртвый» — лицо может быть в углу, а действие в центре. Saliency удерживает в кадре и лицо, и контекст.

4. Детекция сцен и границ шотов (Scene Detection)

Разбиение исходника на атомарные шоты — основа для последующего отбора и перестановки планов. Не путать со склейками внутри готового монтажа.

4.1. Классические методы

- Histogram Difference: разница гистограмм соседних кадров; превышение порога = смена сцены.
- ContentDetector (PySceneDetect): сравнение гистограмм в пространстве HSV — стандарт индустрии для контентных сцен.
- AdaptiveDetector: адаптивный порог — устойчивее к плавным изменениям яркости.
- Edge Change Ratio: изменение доли контуров между кадрами — устойчивее к мельканию света.
- Метод оптического потока: резкое изменение векторов движения как маркер склейки.

4.2. Нейросетевые методы (точнее на сложном материале)

Модель	Назначение
TransNet v2	Быстрая детекция переходов между шотами (deep network)
AutoShot	Shot boundary detection (CVPR 2023)
MLLM (Qwen2-VL, Gemini)	Семантическое слияние шотов одной локации/события

Инструмент: PySceneDetect — `detect(video, ContentDetector())` → список (start, end) по сменам сцен.

Рекомендация. Для большинства задач достаточно PySceneDetect ContentDetector/AdaptiveDetector (быстро, надёжно, без GPU). TransNet v2 — когда нужна максимальная точность на быстром/сложном видео.

5. Выбор лучших фрагментов (Highlight Detection)

Ключевая задача: из массы шотов выбрать самые ценные. Каждому фрагменту присваивается комплексный вес, затем фрагменты ранжируются.

5.1. Взвешенный скоринг фрагмента

Формула веса фрагмента:

$$W_{clip} = \alpha \cdot M_{tech} + \beta \cdot M_{semantic} + \gamma \cdot M_{dynamic}$$

- M_{tech} — техническое качество (раздел 1): отсутствие смаза/пересвета.
- $M_{semantic}$ — смысловая ценность: CLIP-сходство с темой и/или наличие главного объекта

(YOLO).

- `M_dynamic` — динамика: средняя магнитуда оптического потока. Оптимум — СРЕДНИЙ уровень (мало = скучно/статика, много = тряска/брак).

5.2. Триггеры хайлайтов

Тип сигнала	Конкретный метод / модель
Аудио-события	Всплески громкости (RMS); классификаторы смеха/аплодисментов — YAMNet, AST
Эмоции на лице	FER — распознавание выражений (ResNet, FACS); резкая смена нейтрально → радость/удивление
Действия	Action recognition 3D-CNN: I3D, SlowFast, C3D (смех, прыжок, речь)
Семантика	CLIP — поиск кадров под запрос («экшн», «красивый пейзаж»)
Речь	Speech density — слов/сек из ASR; пик речевой плотности = смысловой пик

5.3. Без нейросетей (если ресурсы ограничены)

- Contrastive learning ranking — ранжирование вероятных склеек между парами шотов.
- Data-driven editing — задача последовательного решения retain/remove для каждого шота.
- Эвристика: достаточно скоринга «визуальное качество + движение + речевая плотность» без LLM.

Опционально с LLM. Транскрипцию (Whisper) можно отдать LLM/MLLM (GPT-4o, DeepSeek-R1, Qwen2-VL) для отбора хайлайтов по правилам и оценки кандидатов на роль вступления/концовки. Это улучшает смысловой отбор, но не обязательно для рабочего прототипа.

6. Движение, динамика и стабилизация (Optical Flow)

Назначение: Оценка глобального движения камеры, уровня динамики кадра, тряски и смаза движения.

Алгоритм	Тип	Когда применять
Farneback	Плотный поток	Оценка общей динамики/смаза, стабилизация — баланс скорость/качество
Lucas–Kanade	Разреженный поток	Трекинг отдельных точек, лёгкая оценка движения
DIS Optical Flow	Плотный, быстрый	Когда нужен плотный поток в реальном времени (OpenCV)
RAFT	Deep learning	Максимальная точность потока (нужен GPU)

- Метрика динамики: средняя магнитуда потока → отсеив статичных «скучных» фрагментов (если это не подкаст).
- Стабилизация: компенсация дрожания по оценённому глобальному движению.
- Дисперсия потока внутри кадра: высокая = тряска, низкая = статика.

Инструмент: OpenCV (`calcOpticalFlowFarneback`, `DISOpticalFlow`).

7. Автоматическое кадрирование 16:9 → 9:16 (Auto Reframe)

Динамический кроп горизонтального источника в вертикаль с удержанием главного объекта в кадре.

7.1. Детекция и трекинг объекта

- MediaPipe Face Detection / Face Mesh / Pose — быстрый трекинг лиц и поз на CPU (предпочтительно).
- YOLOv8 — детекция объектов, если есть GPU или нужны не-лица (машины, здания, монументы).
- Трекеры для устойчивости ID между кадрами: DeepSORT, ByteTrack.
- Fallback-цепочка: Лицо → Тело → Объект → центр кадра (если ничего не найдено).

7.2. Сглаживание траектории виртуальной камеры

Проблема: Жёсткая привязка центра кропа к центру лица → видео «дёргается».

Метод сглаживания	Характер
Фильтр Калмана	Предсказание + сглаживание; гасит рывки, учитывает скорость
Скользящее среднее (moving average)	Простейшее сглаживание окна позиций
Гауссово / low-pass сглаживание	Плавная траектория без резких скачков
Кубический сплайн (cubic spline)	Интерполяция между ключевыми кадрами (scipy.interpolate)

7.3. Практические правила (из реализации auto-reframe)

- Только по оси X (горизонтальный сдвиг). Без zoom/stretch/resize.
- Ключевой кадр создаётся только при confidence детекции > 25%.
- Границы сцен (раздел 4) — автоматически становятся ключевыми кадрами.
- Между ключевыми кадрами — интерполяция кубическим сплайном.
- Motion Prediction: предугадывание движения объекта → упреждающая подстройка рамки.

Гибрид (повтор важной рекомендации). Комбинируйте трекинг лица (MediaPipe) с картой салиентности (раздел 3): удерживаете в кадре и говорящего, и смысловой контекст действия.

8. Монтаж под музыку (Beat Detection & Sync)

8.1. Поиск битов

Базовый метод: librosa.beat.beat_track — извлекает темп (BPM) и таймкоды битов.

Как работает: STFT → спектрограмма → onset strength envelope (оглабающая силы атаки звука). Пики оглабающей = биты. Точный темп — динамическим программированием.

- Spectral Flux — нахождение транзиентов (резких всплесков энергии) как точек склейки.
- Onset detection — локальные максимумы оглабающей → массив таймкодов для cut.
- Comb filter по низким частотам — выделение бочки (kick drum); приоритет ударам барабана.
- Essentia — альтернатива librosa для анализа темпа/ритма.

Канонический вызов:

```
import librosa
y, sr = librosa.load('music.mp3')
tempo, beat_frames = librosa.beat.beat_track(y=y, sr=sr)
beat_times = librosa.frames_to_time(beat_frames, sr=sr)
```

8.2. Синхронизация склеек с битами

Задача: Привязать точки склейки видео к таймкодам битов — задача оптимизации.

- Жадный алгоритм (greedy): для каждой склейки берём ближайший бит.
- Динамическое программирование / Витерби: глобально оптимальная привязка всей последовательности.
- Допуск подгонки: сдвиг границы фрагмента на ± 200 мс к ближайшему биту. Приоритет — onset бочки.
- Если видео длиннее интервала между битами — ускорить/обрезать; короче — добавить стык-кадр (B-roll).

8.3. Pacing — темп монтажа от BPM

- Длина одного плана для Reels/TikTok: 1.5–2 сек (короче при высоком BPM).
- Смена кадра кратно битам: каждые 2 или 4 бита.
- Медленный трек → длинные планы + плавные переходы (cross-dissolve).

- Быстрый трек → короткие планы + жёсткие склейки (hard cut).

Главная практическая рекомендация всех записок. Начинайте с аудио. Удаление тишины (раздел 9) + нарезка под биты дают ~70% ощущения «профессионального монтажа» БЕЗ сложного CV.

9. Обработка звука, речь и склейки по словам

9.1. VAD — детекция голоса (тишина/речь)

- Silero VAD — лёгкая модель речь/тишина/шум; удаление тишины = вырезание участков, где VAD = 0.
- Ryannote — VAD и диаризация дикторов (кто когда говорит).
- Применение: Silence Removal, точки начала/конца фраз для аккуратной нарезки.

9.2. ASR — распознавание речи с таймкодами

Модель: OpenAI Whisper / faster-whisper (CTranslate2 — быстрее).

Ключевое: Word-level timestamps — таймкод каждого слова. Критично для нарезки по словам и динамических субтитров.

Логика: Текст привязан к таймкодам → удаление слова из транскрипции = вырезание куска видео (text-based editing).

9.3. Сопутствующая обработка

- Demucs — разделение голоса и музыки (когда нужно чистить дорожку).
- Loudness normalization до -14 LUFS — стандарт громкости для соцсетей.
- RMS amplitude — оценка громкости, поиск аудио-пику (хайлайты).
- Speaker diarization — разделение по говорящим (подкасты, многокамерный монтаж).

9.4. Сглаживание jump cut (после вырезания пауз/слов)

- Микро-зум: scale up на 5–10% на склейке — маскирует рывок.
- RIFE — интерполяция промежуточных кадров (frame interpolation) для плавности.
- Whip-pan / cut-on-action: склейка в движении, когда направление и скорость потока схожи.

10. Структура ролика: методы отбора (Story Arc)

Не архитектура, а конкретные приёмы выбора фрагментов под драматургию короткого ролика.

Элемент	Метод определения фрагмента
Hook (0–3 сек)	Кадр с макс. салиентностью ИЛИ макс. аудио-энергией; фразы с вопросом/цифрой/сильным утверждением в начале
Context / Body	2–3 фразы по теме; шоты с высокой речевой/семантической плотностью (по транскрипции)
Climax	Sentiment Analysis текста — фразы с сильной эмоциональной окраской
Outro / CTA	Поиск фраз-призывов («подпишись», «смотри», «subscribe»)

- Правило: шот с максимальным динамическим/семантическим скором — принудительно в первые 3 секунды.
- Pacing: чередование планов (крупный → средний), средняя длина кадра 1.5–3 сек.

11. Метрики оценки качества

11.1. Уровень кадра (Frame-level)

Метрика	Как считается / порог
Blur Score	Дисперсия Лапласиана; $< \sim 100 \rightarrow$ отбрасываем
Exposure Score	Среднее канала Y (YUV); отсев чистого чёрного/белого
Aesthetic Score	Выход NIMA, 1–10; ранжирование дублей
Face/IoU Score	Пересечение bbox лица с центральной зоной кадра (важно для 9:16)
Saliency Focus	Площадь salient-объекта в центре / общая площадь

11.2. Уровень фрагмента (Segment-level)

Метрика	Смысл
Speech Density	Время речи / длительность; отсев фрагментов, где $>80\%$ тишина
Motion Variance	Средняя магнитуда оптического потока; отсев статики
Semantic Relevance	Cosine similarity CLIP(кадр) и промпта сценария
Semantic Coherence	CLIP-сходство первого и последнего кадра шота (нет смыслового скачка)

11.3. Уровень монтажа (Cut / Video-level)

Метрика	Смысл / формула
Beat Sync Error	RMSE между таймкодами склеек и ближайших битов; меньше = ритмичнее
Shot Length Variance	Дисперсия длин планов; должна соответствовать дисперсии битов
Jump Cut Penalty	Штраф за склейки с минимальной разницей кадров (дёрганье)
Audio-Visual Sync	Корреляция аудио-транзиентов и резких визуальных смен
Diversity	$1 - \text{средний IoU}$ между вариантами монтажа (креативность)
Smoothness	$\text{Duration} / (1 + \text{Interruption})$ — ср. длина без рваных переходов
Engagement	Доля просмотра на нормальной скорости (vs $2\times$ / skip)
VEI	$\text{Engagement} \times \text{Smoothness}$ — холистическое качество
Hook / Suspense Rate	Аттрактивность вступления / мотивация досмотреть концовку

12. Сводная таблица инструментов (open source)

Задача	Инструмент / библиотека	Установка / примечание
Декодирование, нарезка, рендер	FFmpeg (ffmpeg-python), MoviePy, PyAV	FFmpeg — ядро; MoviePy — высокоуровневый API
Детекция сцен	PySceneDetect	<code>pip install scenedetect</code>
Биты, темп, громкость	librosa, Essentia, aubio	<code>pip install librosa</code>
ASR (речь→текст)	faster-whisper, whisper.cpp	word-level timestamps
VAD (тишина/речь)	Silero VAD, Pyannote	лёгкая модель
Разделение голос/музыка	Demucs	очистка дорожки
CV база, оптический поток	OpenCV	<code>pip install opencv-python (+contrib для BRISQUE)</code>
Лица, позы, объекты	MediaPipe, YOLOv8 (ultralytics)	MediaPipe — CPU; YOLO — GPU
Трекинг объектов	DeepSORT, ByteTrack, SAM	удержание ID между кадрами
Семантика кадр↔текст	CLIP, BLIP-2 (Transformers)	<code>pip install transformers</code>

Задача	Инструмент / библиотека	Установка / примечание
Эстетика / качество	NIMA (PyTorch), DIQA, CLIP-IQA, BRISQUE	ранжирование кадров
ML-рантайм	PyTorch, ONNX Runtime	ускорение GPU/CPU

13. Сводка ключевых рекомендаций

- 1. Начинайте с аудио. Silence Removal + нарезка под биты = ~70% «профессионализма» без сложного CV.
- 2. Каскад фильтров. Дешёвые эвристики OpenCV (резкость/экспозиция) — на всё видео; тяжёлые нейросети (NIMA, CLIP, YOLO) — только на кадры-кандидаты. Покадровый ML по всему видео слишком дорог.
- 3. Резкость = дисперсия Лапласиана (порог ~100); экспозиция = гистограмма Y. Это базовый «детектор брака».
- 4. Эстетика = NIMA (1–10) или LAION/CLIP-предиктор; влияет на выбор лучшего из дублей.
- 5. Смысл = CLIP-эмбединги + cosine similarity к текстовому промпту-сценарию.
- 6. Сцены = PySceneDetect (ContentDetector, HSV-гистограммы); TransNet v2 — для сложного материала.
- 7. Хайлайты = взвешенный скор $W = \alpha \cdot \text{tech} + \beta \cdot \text{semantic} + \gamma \cdot \text{dynamic}$ + аудио-триггеры (громкость, смех, эмоции).
- 8. Динамика = магнитуа оптического потока (Farnebäck); оптимум — средний уровень движения.
- 9. Авто-кроп 9:16 = MediaPipe (лицо) + Saliency (контекст), сглаживание Калманом / сплайном, только по X.
- 10. Музыка = librosa.beat.beat_track; склейки в ± 200 мс к биту, приоритет бочке; racing по BPM.
- 11. Контекстные переходы. Если поток в конце кадра А и начале Б схож по направлению/скорости — склейка в движении (cut on action) вместо реза «под корень».
- 12. Метрики обязательны: Beat Sync Error (RMSE), Shot Length Variance, VEI, Hook Rate — для авто-оценки результата.